

PRESENTACIÓN

ROADSCENE SEGMENTATION FOR AUTONOMOUS VEHICLES

JOHAN SEBASTIAN MENDIETA
SEBASTIAN TORRES

Índice.



- Problemática
- Propuesta
- Distribución de datos
- Configuración
- Arquitectura y Explicación técnica
- Resultados
- Métricas de rendimiento
- Gráfica de progreso

Problemática

- Los vehículos autónomos necesitan identificar su entorno con alta precisión.
- Factores como tráfico, peatones y condiciones ambientales dificultan esta tarea.
- Los métodos tradicionales no delimitan los objetos con suficiente detalle.
- Se requiere segmentación inteligente para mejorar la seguridad y la toma de decisiones.

Una percepción precisa del entorno es fundamental para garantizar una conducción autónoma segura y eficiente

¿Por que segmentación?

La segmentación semántica es útil para asistencia a conducción porque permite identificar zonas transitables, obstáculos y elementos urbanos con mayor detalle que una clasificación simple o una caja delimitadora.



Datos

Dataset: CamVid

Clases: 32

Distribución:

- **Train: 369 imágenes**
- **Validación: 100 imágenes**
- **Test: 232 imágenes**
- **Tamaño original: 960 × 720**
- **Tamaño usado: 256 × 384**




- Vacío
- Cielo
- Edificio
- Carretera
- Andén
- Árbol
- Vegetación diversa
- Columna
- Cerca
- Muro
- Puente
- Señal
- Texto diverso
- Semáforo

- Cono de tráfico
- Berma / borde de vía
- Marcas de carril transitable
- Marcas de carril no transitable
- Bloque de parqueadero
- Túnel
- Arco / estructura arqueada
- Carro
- Camioneta / pickup
- Camión / bus
- Tren
- Otro objeto en movimiento
- Peatón
- Niño

- Ciclista
- Motocicleta / scooter
- Animal
- Carrito / equipaje / coche de bebé

Clases





Configuración

- **Tamaño de imagen:** 256 × 384 píxeles
- **Batch size:** 4
- **Épocas:** 100
- **Learning rate:** 0.0003
- **Optimizador:** AdamW
- **Weight decay:** 0.0001
- **Canales base de la U-Net:** 32
- **Función de pérdida:** Cross Entropy + Dice Loss
- **Peso de Cross Entropy:** 70%
- **Peso de Dice Loss:** 30%
- **Pesos por clase:** activados
- **Mixed precision:** activado
- **Dispositivo:** GPU si está disponible
- **Semilla:** 42

U-Net

La usamos porque el proyecto es de segmentación semántica, es decir, el modelo no solo debe decir qué hay en la imagen, sino clasificar cada píxel de la imagen.


¿Por qué U-Net?























Porque U-Net está diseñada para tareas donde se necesita una salida con forma de imagen, como una máscara de segmentación.

En nuestro caso:

- Entra una imagen RGB de la calle.
- Sale una máscara, donde cada píxel pertenece a una clase: carretera, cielo, edificio, carro, peatón, árbol, etc.

ARQUITECTURA






Imagen



Carretera real



Carretera por PDI clásica



Imagen



Carretera real




Carretera por PDI clásica




Imagen



Máscara real



Predicción




Superposición predicha



Imagen




Máscara real



Predicción




Superposición predicha




Imagen



Máscara real



Predicción



Superposición predicha



Resultados

El modelo logró un desempeño positivo en la tarea de segmentación semántica, alcanzando una precisión por píxel de 86.34%. Esto indica que la mayoría de los píxeles fueron clasificados correctamente. Además, la curva de entrenamiento muestra que el modelo aprendió progresivamente, ya que la pérdida disminuyó y el IoU de validación aumentó hasta alcanzar su mejor resultado cerca de la época 95.

Sin embargo, el IoU en test fue de 0.4104, lo que evidencia que el modelo todavía tiene dificultades para segmentar todas las clases con alta precisión. Las mejores predicciones se dieron en clases grandes y frecuentes como carretera, cielo, edificios y aceras, mientras que clases pequeñas o poco representadas, como señales, conos, peatones o motocicletas, presentaron menor rendimiento. En general, la arquitectura U-Net fue adecuada para el problema, aunque los resultados podrían mejorar con más datos, mejor balance de clases o arquitecturas más avanzadas.

IVCUT

Pérdida en test

1.0345

Precisión por píxel

86.34%

IoU en test

0.4104

Dice en test


0.5315

Mejor época

95


IoU de validación




0.5059



Clase predicha

IoU por clase en test





Rendimiento